Ejercicio 01 · Unidad 02 (LAB04 + LAB05)

Corpus público, auditoría, clasificación de sentimiento y análisis de errores

Estudiante	Edwing Perez
Repositorio	https://github.com/edvvdev/unidad02-01
Curso	INF-8239 Ciencia de Datos II · Unidad 02
Fecha del informe	2026-11-05
Repositorio del enunciado	https://github.com/edvvdev/unidad02-01

Este informe resume la seleccion del corpus, la auditoria, la comparacion de tres pipelines de clasificacion y el analisis de errores. Todas las cifras proceden de los artefactos versionados en **reports/** y el flujo completo se reproduce con **scripts/run_all.sh**.

1. Corpus elegido y trazabilidad

Campo	Valor
Nombre	Sentiment Labelled Sentences (UCI 331)
Ficha original	https://archive.ics.uci.edu/dataset/331/sentiment-labelled-sentences
Descarga	https://archive.ics.uci.edu/static/public/331/sentiment+labelled+sentences.zip
Licencia	CC BY 4.0 (permite uso academico y publicar resultados derivados)
Creacion	Kotzias et al., KDD 2015 · DOI 10.24432/C57604
Filas / columnas	3000 filas · sentence, score, source
Variable objetivo	score (0 = negativo, 1 = positivo)
Clases	2 balanceadas (1500 / 1500)
SHA-256 del ZIP	afc26626d710899948693e1a61405dce197f57ffa719fa1130d346b4cc095343
SHA-256 del CSV	6410f6b155301ad6a1cd47d90de2e44a5a82f938d4f13d500400a1eafea069fd
Duplicados	18 textos duplicados, eliminados antes de partir
Nulos / vacios	0 nulos · 0 textos vacios
Longitud de texto	p50 10 · p90 22 · p99 36 palabras

Candidato descartado: UCI 228 SMS Spam Collection (5.574 mensajes ham/spam, CC BY 4.0). Se descarta porque contiene mensajes reales de usuarios con numeros y enlaces (419 filas con 7+ digitos y 140 con URL o correo), presenta un desbalance de 13,4 % de spam y su objetivo no es el sentimiento. El contraste completo esta en **docs/dataset_candidates.csv**.

Hallazgo sobre los datos crudos: el archivo de IMDb contiene comillas dobles dentro del texto y dos caracteres U+0085 (NEXT LINE) incrustados en frases. Un lector CSV ingenuo pierde 252 de las 1.000 filas de IMDb (780 de 3.000 con separador coma). La solucion aplicada corta el archivo solo por el salto de linea y separa cada linea por su ultimo tabulador, y recupera las 3.000 filas completas.

2. Resultados de los tres pipelines

Particion estratificada 75/25 con semilla 42 sobre 2982 filas utiles (2236 de entrenamiento y 746 de prueba). El vectorizador TF-IDF esta dentro de cada pipeline, de modo que no hay fuga de informacion. Metrica de decision: F1 macro.

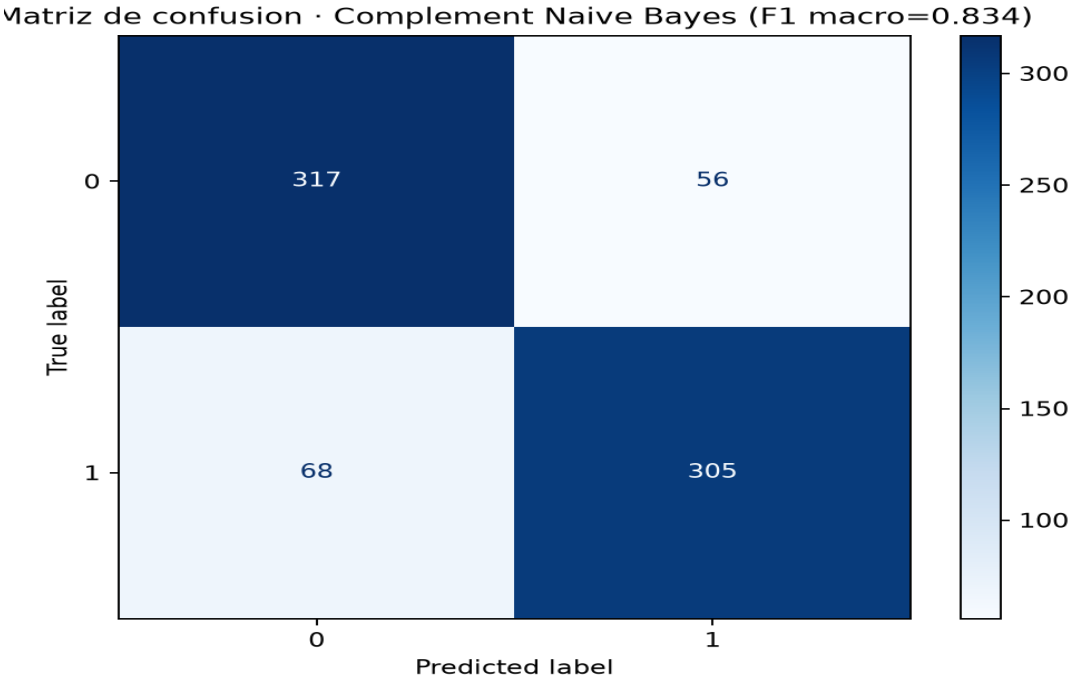
Modelo	F1 macro	Accuracy	Precision macro	Recall macro	Seleccionad
Complement Naive Bayes	0.834	0.834	0.834	0.834	Si
Regresion logistica con TF-IDF	0.814	0.814	0.814	0.814	No
DummyClassifier (linea base)	0.333	0.500	0.250	0.500	No

Metricas por clase del modelo seleccionado

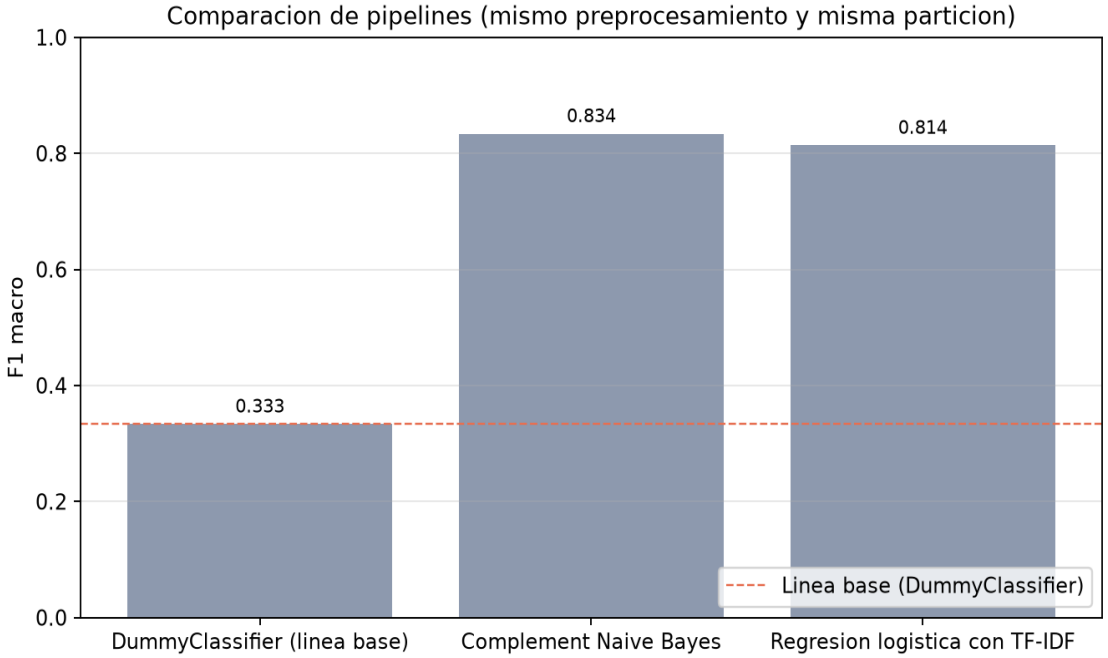
Clase	Precision	Recall	F1	Support
0 (negativo)	0.823	0.850	0.836	373
1 (positivo)	0.845	0.818	0.831	373

El script base fijaba la regresion logistica como modelo final; el manual pide guardar el mejor segun la metrica, y en este corpus gana Complement Naive Bayes (F1 macro 0.834 frente a 0.814 de la regresion logistica y 0.333 de la linea base).

Matriz de confusion del modelo seleccionado



Comparacion de F1 macro entre pipelines



3. Analisis de errores

El modelo seleccionado comete 124 errores sobre 746 filas de prueba. Cada error se categoriza con reglas lexicas transparentes (20 categorias, la primera que se activa) y se guardan las senales que la activaron. Se revisaron manualmente 20 errores con su interpretacion en **notebooks/01_ejercicio01_nlp.ipynb** y en **reports/error_sample_20_reviewed.csv**.

Categoria	Errores	% del total
senal_no_cubierta	37	29.84%
hecho_sin_valoracion	18	14.52%
contraste	12	9.68%
negacion	12	9.68%
comparacion	8	6.45%
hiperbole	6	4.84%
dialecto_registro_informal	6	4.84%
texto_corto	5	4.03%
condicion_o_recomendacion	3	2.42%
enfasis_mayusculas	3	2.42%
multiples_aspectos	3	2.42%
experiencia_personal	3	2.42%
formato_precios	3	2.42%
duda_hedging	2	1.61%
etiqueta_discutible	1	0.81%
modismo_expresion	1	0.81%
lang_indice_tecnico	1	0.81%

Tres reglas no se activaron en este corpus (ironia, atribucion a terceros y fuera del dominio): el corpus es homogeneo en registro, no contiene enunciados ironicos ni citas atribuidas y todas las frases son resenas de producto, pelicula o restaurante.

Figura 3. Reparto de errores por categoria

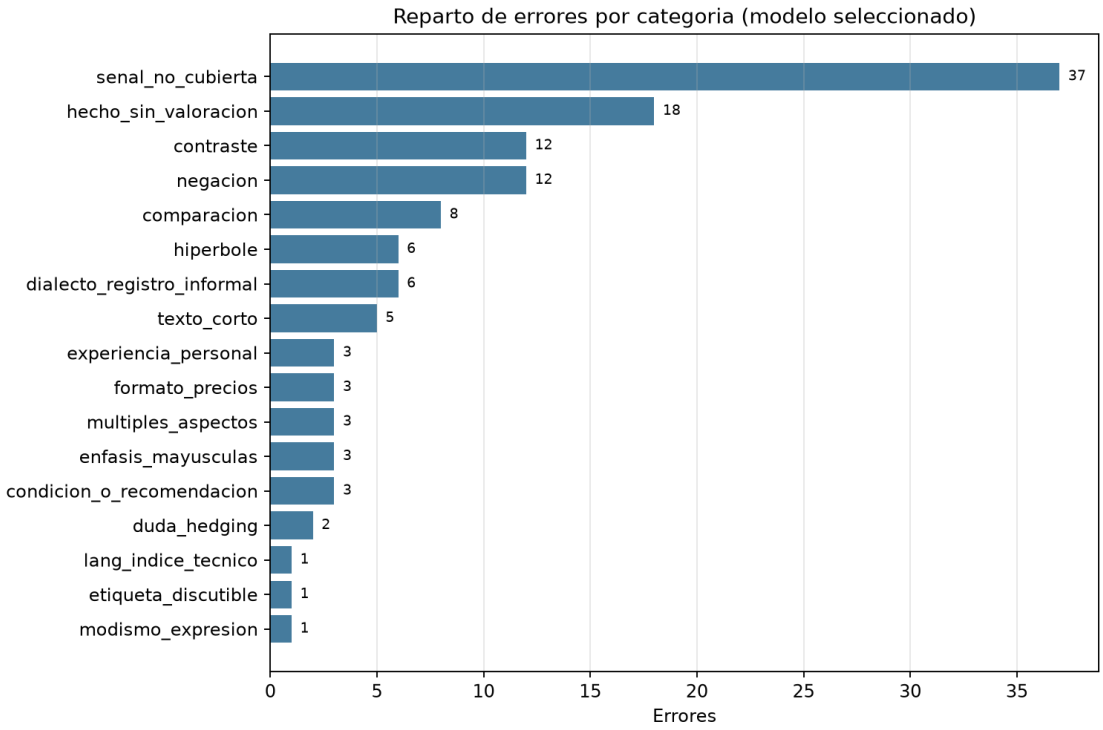
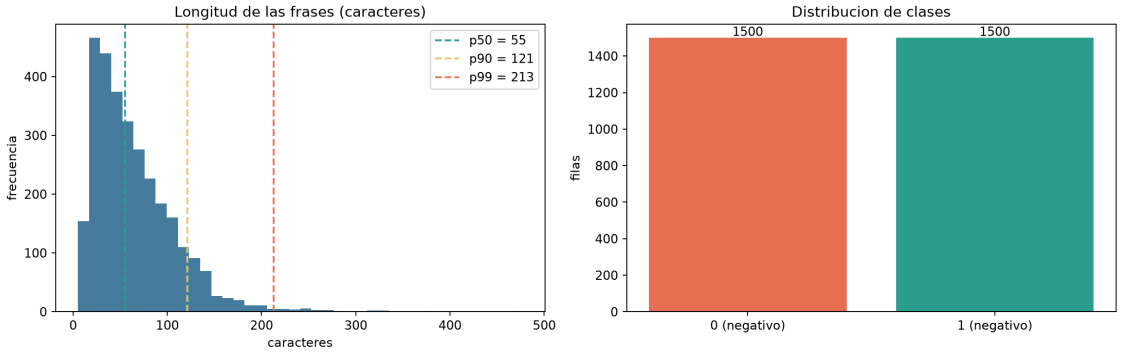


Figura 4. Longitud de las frases y distribucion de clases



4. Conclusion

La pregunta del ejercicio se respondio con un corpus publico, verificado y auditable: Sentiment Labelled Sentences de UCI, con 3000 frases en ingles, 2 clases balanceadas y licencia CC BY 4.0. La revision del archivo crudo fue decisiva: un lector CSV ingenuo habria perdido 252 de las 1.000 filas de IMDb y dos registros habrian quedado sin etiqueta por dos caracteres U+0085 incrustados en las frases. Separar cada linea por su ultimo tabulador y cortar solo por el salto de linea recupera las 3000 filas completas y deja el hash SHA-256 registrado en el manifiesto de procedencia. La auditoria adicional detecto 18 textos duplicados, sin ninguna etiqueta contradictoria, que se eliminan antes de la particion estratificada para que ningun texto aparezca en entrenamiento y prueba a la vez. En la comparacion de modelos, la linea base obtiene un F1 macro de 0.333, la regresion logistica 0.814 y Complement Naive Bayes 0.834. El script base fijaba la regresion logistica como modelo final, pero el manual pide guardar el mejor segun la metrica, de modo que se guarda Complement Naive Bayes con F1 macro 0.834 frente a la linea base. La matriz de confusion muestra que el modelo pierde sobre todo la clase positiva: 68 reseñas positivas se clasificaron como negativas, frente a 56 negativas clasificadas como positivas. El recall de la clase positiva (0.818) queda por debajo del de la negativa (0.850), aunque su precision sea mayor (0.845). El error mas costoso en este contexto es, por tanto, registrar como negativa una reseña positiva. El analisis de 124 errores con 20 reglas lexicas transparentes muestra que las categorias mas frecuentes son senal_no_cubierta (37), hecho_sin_valoracion (18), contraste (12). La predominancia de la senal no cubierta indica que el fallo dominante no es un fenomeno linguistico raro sino la combinacion de rasgos: el modelo dispone del vocabulario pero no del contexto que fija el sentido de una frase. Las reglas de ironia, atribucion a terceros y fuera del dominio no se activaron nunca, lo que confirma que el corpus es homogeneo en registro y que no cubre ninguna de esas dimensiones. La decision antes de publicar es clara: el modelo sirve como senal de apoyo dentro del dominio y el idioma del corpus, nunca como veredicto sobre una persona, una obra o un negocio. Las limitaciones que deben comunicarse son importantes: el corpus es en ingles, anterior a 2015, de frases cortas de resenas en linea, con un balance de clases artificial y sin clase neutral, por lo que las cifras no se generalizan a espanol, a otros periodos ni a otros dominios.

5. Uso responsable de inteligencia artificial

Se utilizo un asistente de IA para apoyar la estructura del proyecto, la redaccion de la documentacion y la redaccion de las pruebas automaticas. No se uso para generar datos, etiquetas ni resultados. Toda afirmacion numerica de este informe se verifico ejecutando el codigo del repositorio: el hash SHA-256 del corpus se comparo con el archivo descargado, la auditoria se contrasto con un calculo independiente, la matriz de confusion se comprobo contra los suportes por clase y cada cifra de este PDF se lee de los archivos JSON y CSV de reports/. El uso de IA quedo registrado, junto con los prompts relevantes, las partes verificadas y las correcciones realizadas, en el archivo AI_USE_DECLARATION.md del repositorio. El estudiante conserva la responsabilidad sobre los datos, el codigo, las referencias y las conclusiones.