Ejercicio 03 de la Unidad 02 (LAB04 + LAB05)

Corpus público, auditoría, clasificación de sentimiento y análisis de errores

Estudiante	Edwing Perez
Repositorio	https://github.com/edvvdev/unidad02-01
Curso	INF-8239 Ciencia de Datos II · Unidad 02
Ejercicio	Ejercicio 03 de la Unidad 02 (LAB04 + LAB05)
Fecha del informe	2026-11-06

Nota sobre el nombre del ejercicio. El mandato de la unidad numera este trabajo como Ejercicio 03; en el repositorio aparece como Ejercicio 01 por orden de entrega dentro de la unidad.

Este informe resume la selección del corpus, la auditoría, la comparación de tres pipelines de clasificación y el análisis de errores. Todas las cifras proceden de los artefactos versionados en **reports/** y el flujo completo se reproduce con **scripts/run_all.sh**.

1. Corpus elegido y trazabilidad

Campo	Valor
Nombre	UCI 331 - Sentiment Labelled Sentences
Ficha original	https://archive.ics.uci.edu/dataset/331/sentiment-labelled-sentences
Descarga	https://archive.ics.uci.edu/static/public/331/sentiment+labelled+sentences.zip
Licencia	CC BY 4.0
Filas / columnas	3.000 filas · sentence, score, source
Variable objetivo	score (0=negativo; 1=positivo)
Clases	2 balanceadas (1.500 / 1.500)
SHA-256 del ZIP	afc26626d710899948693e1a61405dce197f57ffa719fa1130d346b4cc095343
SHA-256 del CSV	6410f6b155301ad6a1cd47d90de2e44a5a82f938d4f13d500400a1eafea069fd
Duplicados	18 textos duplicados, eliminados antes de partir
Nulos / vacíos	0 nulos · 0 textos vacíos
Longitud de texto	p50 10 · p90 22 · p99 36 palabras
Datos personales	no (0 correos; 0 telefonos; 0 URLs; solo fragmentos de resenas publicas)

Candidato descartado: SMS Spam Collection (UCI 228) (5.574 mensajes: 4.827 ham y 747 spam, 13.4 % de spam, CC BY 4.0). Se descarta porque contiene mensajes reales de usuarios con números y enlaces (419 filas con 7 o más dígitos y 113 con URL o dirección de correo; 141 si se cuenta cualquier mensaje con un símbolo @), presenta un desbalance de 13.4 % de spam y su objetivo no es el sentimiento. El contraste completo está en **docs/dataset_candidates.csv**: Contiene mensajes reales de usuarios (informacion personal y potencial spam) que el manual excluye; el objetivo del corpus es filtrar spam y no medir sentimiento, por lo que no responde la pregunta del ejercicio; ademas presenta desbalance fuerte y 403 duplicados

Hallazgo sobre los datos crudos: el archivo de IMDb contiene comillas dobles dentro del texto y 2 caracteres U+0085 (NEXT LINE) incrustados en frases. Un lector CSV ingenuo con separador coma pierde 261 de las 1.000 filas de IMDb, 225 de las 1.000 filas de Amazon y 294 de las 1.000 filas de Yelp: 780 de las 3.000 filas del corpus. Con separador tabulador se pierden 252 de las 1.000 filas de IMDb. La solución aplicada corta el archivo solo por el salto de línea y separa cada línea por su último tabulador, y recupera las 3.000 filas completas.

2. Resultados de los tres pipelines

Partición estratificada 75/25 con semilla 42 sobre 2.982 filas útiles (2.236 de entrenamiento y 746 de prueba). El vectorizador TF-IDF está dentro de cada pipeline, de modo que no hay fuga de información. Métrica de decisión: F1 macro.

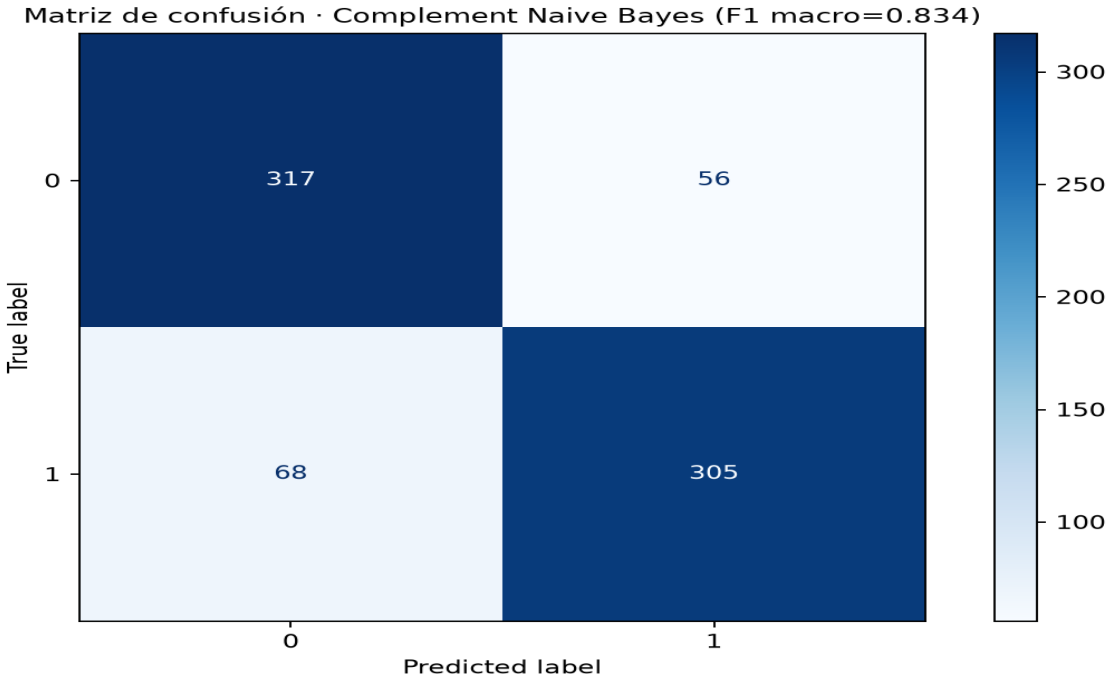
Modelo	F1 macro	Accuracy	Precisión macro	Recall macro	Seleccionado
Complement Naive Bayes	0.834	0.834	0.834	0.834	Sí
Regresión logística con TF-IDF	0.814	0.814	0.814	0.814	No
Línea base (DummyClassifier)	0.333	0.500	0.250	0.500	No

Métricas por clase del modelo seleccionado

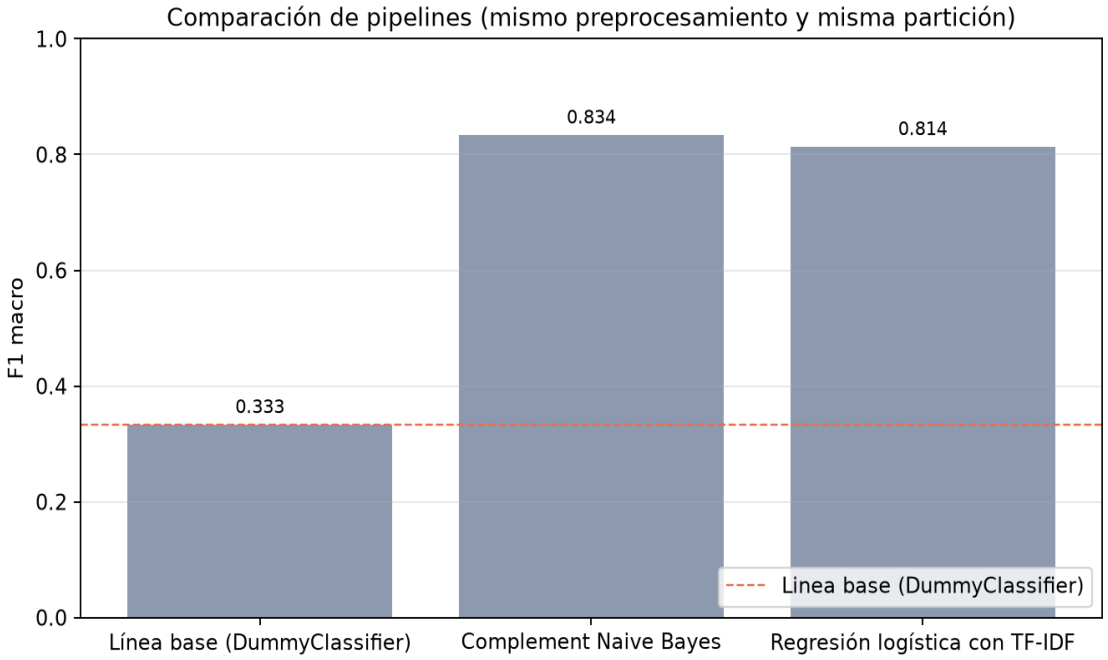
Clase	Precisión	Recall	F1	Support
0 (negativo)	0.823	0.850	0.836	373
1 (positivo)	0.845	0.818	0.831	373

El script base fijaba la regresión logística como modelo final; el manual pide guardar el mejor según la métrica, y en este corpus gana Complement Naive Bayes (F1 macro 0.834 frente a 0.814 de la regresión logística y 0.333 de la línea base).

Matriz de confusión del modelo seleccionado



Comparación de F1 macro entre pipelines



3. Análisis de errores

El modelo seleccionado comete 124 errores sobre 746 filas de prueba. Cada error se categoriza con 20 categorías de reglas léxicas transparentes (la primera que se activa) y se guardan las señales que la activaron. Se revisaron manualmente 20 errores con su interpretación en **notebooks/01_ejercicio01_nlp.ipynb** y en **reports/error_sample_20_reviewed.csv**.

Categoría	Errores	% del total
senal_no_cubierta	37	29.84 %
hecho_sin_valoracion	18	14.52 %
contraste	12	9.68 %
negacion	12	9.68 %
comparacion	8	6.45 %
hiperbole	6	4.84 %
dialecto_registro_informal	6	4.84 %
texto_corto	5	4.03 %
condicion_o_recomendacion	3	2.42 %
enfasis_mayusculas	3	2.42 %
multiples_aspectos	3	2.42 %
experiencia_personal	3	2.42 %
formato_precios	3	2.42 %
duda_hedging	2	1.61 %
etiqueta_discutible	1	0.81 %
modismo_expresion	1	0.81 %
lang_indice_tecnico	1	0.81 %

3 reglas no se activaron en este corpus (ironía, atribución a terceros y fuera del dominio): el corpus es homogéneo en registro, no contiene enunciados irónicos ni citas atribuidas y todas las frases son reseñas de producto, película o restaurante.

Figura 3. Reparto de errores por categoría

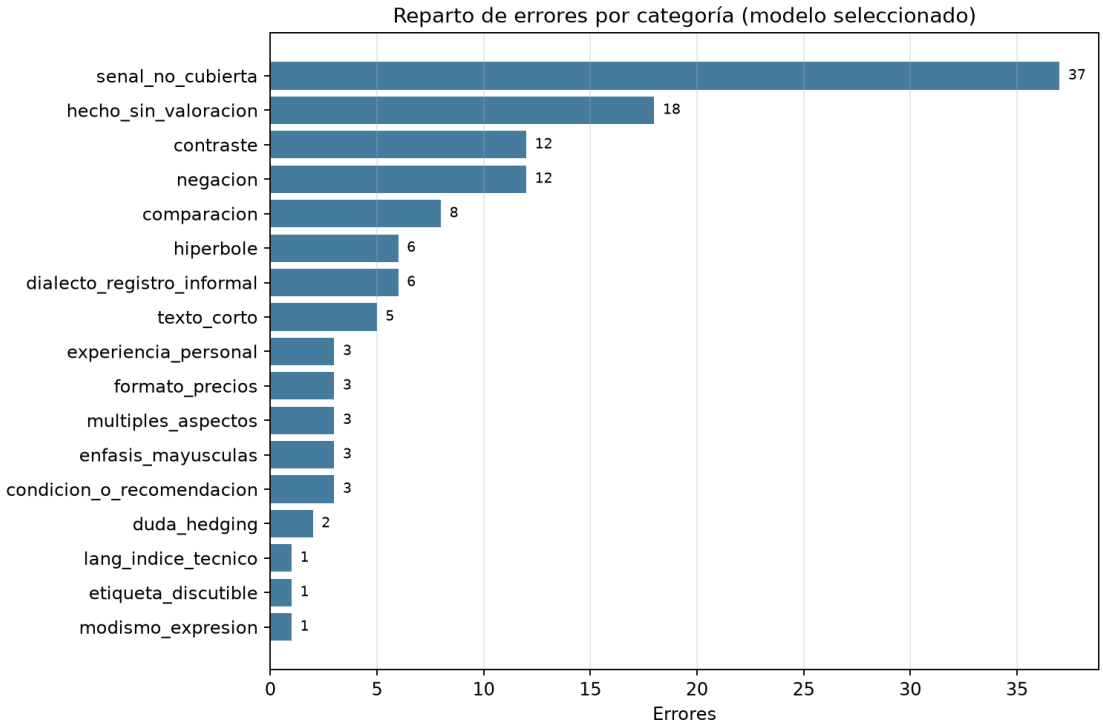
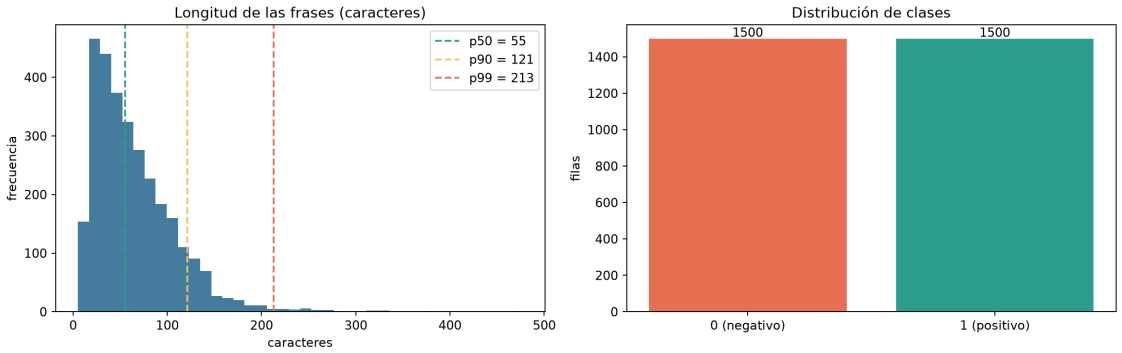


Figura 4. Longitud de las frases y distribución de clases



4. Conclusión

La pregunta del ejercicio se respondió con un corpus público, verificado y auditable: Sentiment Labelled Sentences de UCI, con 3.000 frases en inglés, 2 clases balanceadas y licencia CC BY 4.0. La revisión del archivo crudo fue decisiva: un lector CSV ingenuo habría perdido 261 de las 1.000 filas de IMDb, 225 de las 1.000 filas de Amazon y 294 de las 1.000 filas de Yelp, es decir 780 de las 3.000 filas, y 2 caracteres U+0085 (NEXT LINE) incrustados en las frases habrían dejado otros registros sin etiqueta. Separar cada línea por su último tabulador y cortar solo por el salto de línea recupera las 3.000 filas completas y deja el hash SHA-256 registrado en el manifiesto de procedencia. La auditoría adicional detectó 18 textos duplicados, sin ninguna etiqueta contradictoria, que se eliminan antes de la partición estratificada para que ningún texto aparezca en entrenamiento y prueba a la vez. En la comparación de modelos, la línea base obtiene un F1 macro de 0.333, la regresión logística 0.814 y Complement Naive Bayes 0.834. El script base fijaba la regresión logística como modelo final, pero el manual pide guardar el mejor según la métrica, de modo que se guarda Complement Naive Bayes con F1 macro 0.834 frente a la línea base. La matriz de confusión muestra que el modelo pierde sobre todo la clase positiva: 68 reseñas positivas se clasificaron como negativas, frente a 56 negativas clasificadas como positivas. El recall de la clase positiva (0.818) queda por debajo del de la negativa (0.850), aunque su precisión sea mayor (0.845). El error más costoso en este contexto es, por tanto, registrar como negativa una reseña positiva. El análisis de 124 errores con 20 reglas léxicas transparentes muestra que las categorías más frecuentes son senal_no_cubierta (37), hecho_sin_valoracion (18), contraste (12). La predominancia de la señal no cubierta indica que el fallo dominante no es un fenómeno lingüístico raro sino la combinación de rasgos: el modelo dispone del vocabulario pero no del contexto que fija el sentido de una frase. Las reglas de ironía, atribución a terceros y fuera del dominio no se activaron nunca, lo que confirma que el corpus es homogéneo en registro y que no cubre ninguna de esas dimensiones. La decisión antes de publicar es clara: el modelo sirve como señal de apoyo dentro del dominio y el idioma del corpus, nunca como veredicto sobre una persona, una obra o un negocio. Las limitaciones que deben comunicarse son importantes: el corpus es en inglés, anterior a 2015, de frases cortas de reseñas en línea, con un balance de clases artificial y sin clase neutral, por lo que las cifras no se generalizan a español, a otros periodos ni a otros dominios.

5. Uso responsable de inteligencia artificial

Se utilizó un asistente de IA para apoyar la estructura del proyecto, la redacción de la documentación y la redacción de las pruebas automáticas. No se usó para generar datos, etiquetas ni resultados. Toda afirmación numérica de este informe se verificó ejecutando el código del repositorio: el hash SHA-256 del corpus se comparó con el archivo descargado, la auditoría se contrastó con un cálculo independiente, la matriz de confusión se comprobó contra los soportes por clase y cada cifra de este PDF se lee de los archivos JSON y CSV de reports/ y de la comparación de candidatos. El uso de IA quedó registrado, junto con los prompts relevantes, las partes verificadas y las correcciones realizadas, en el archivo AI_USE_DECLARATION.md del repositorio. El estudiante conserva la responsabilidad sobre los datos, el código, las referencias y las conclusiones.